

فصل سوم

روش‌شناسی تحقیق

طراحی، فرمول‌بندی و عملیاتی‌سازی مدل ترکیبی *DQN-ABM*
برای مسئله تخصیص پویای تاکسی آنلاین

۱-۳ مقدمه فصل

در فصل دوم، چارچوب نظری پژوهش در پنج بخش به تفصیل تشریح شد: مبانی مسئله تخصیص کلاسیک و تعمیم‌های پویای آن (بخش ۲-۲)، چارچوب ریاضی فرآیند تصمیم مارکوف و الگوریتم‌های یادگیری تقویتی شامل معادلات بلمن و خانواده الگوریتم‌های DQN (بخش ۳-۲)، مبانی مدل‌سازی عامل‌بنیان (بخش ۴-۲)، منطق و معماری‌های ترکیب RL و ABM (بخش ۵-۲)، و پیشینه نظام‌مند پنج جریان فکری ادبیات (بخش ۶-۲). سپس شش شکاف تحقیقاتی صورت‌بندی شد و چارچوب مفهومی حلقه‌بسته DQN-ABM به‌عنوان پاسخ ساختاری به این شکاف‌ها معرفی گردید.

فصل حاضر وظیفه عملیاتی‌سازی (Operationalization) آن چارچوب مفهومی را بر عهده دارد. تمامی تصمیمات طراحی — شامل فرمول‌بندی ریاضی دقیق مسئله، تعریف عملیاتی فضای حالت و فضای اقدام، معماری شبکه عصبی، ساختار مدل شبیه‌سازی عامل‌بنیان، قوانین رفتاری عوامل، طرح آزمایش، آزمون‌های آماری و پروتکل بازتولیدپذیری — در این فصل تبیین می‌شوند. مفاهیم نظری پایه که پیش‌تر در فصل دوم تشریح شده‌اند تکرار نمی‌شوند؛ تنها به ارجاعات متقاطع بسنده شده و تمرکز بر تصمیمات طراحی خاص این پژوهش است.

۱-۱-۳ اصلاحات روش‌شناختی نسبت به نسخه‌های پیشین

فصل حاضر شامل پنج اصلاح روش‌شناختی مهم نسبت به نسخه‌های اولیه است که به‌منظور رفع ابهامات و تقویت قابلیت دفاع طراحی صورت گرفته‌اند. این اصلاحات، در پاسخ به یک بازبینی نقدمحور درونی بر اساس معیارهای استاندارد ژورنال‌های Q1 حوزه ITS و RL طراحی شده‌اند و در بخش‌های مربوطه با توجیه کامل ارائه می‌شوند:

(۱) یکپارچه‌سازی نهایی ابعاد بردار حالت در ۳۲ بُعد (با هماهنگ‌سازی متناظر فصول اول و دوم).

(۲) بازطراحی معماری فضای اقدام از رویکرد «شاخص Top-K» (که نسبت به جابه‌جایی ترتیب کاندیدها وابسته است) به رویکرد $Q(s, a_{features})$ که هر جفت کاندید را به‌طور جداگانه امتیازدهی می‌کند و نسبت به جابه‌جایی کاندیدها ناوردا (Permutation-Invariant) است.

(۳) تثبیت نهایی تابع پاداش به‌صورت $R = -\alpha \cdot WT_norm + \beta \cdot DU_norm - \lambda \cdot \mathbb{I}[reject]$ با $\alpha=0.6$ ، $\beta=0.4$ ، $\lambda=0.2$ ؛ همراه با طراحی صریح تحلیل حساسیت روی این ضرایب.

(۴) تعیین دقیق پروتکل ساخت گذار (Transition Construction Protocol) در مکانیزم تخصیص دسته‌ای، که در نسخه قبلی منبع ابهام جدی بود. هر تخصیص (driver-passenger pair) به‌عنوان یک گذار مستقل ذخیره می‌شود.

(۵) گسترش طول آموزش از ۵۰۰ به ۱۰۰۰ اپیزود همراه با معیار توقف زودهنگام (Early Stopping) با $patience=50$ ، و افزایش مدل پذیرش راننده برای انعکاس صریح اثرات کیفیت مقصد و طول سفر.

۲-۱-۳ ساختار فصل

ساختار فصل بدین شرح است: بخش ۲-۳ طراحی کلی پژوهش شامل فلسفه، رویکرد و فرآیند اجرایی را تشریح می‌کند. بخش ۳-۳ داده‌های پژوهش شامل توصیف کامل ۳۶ ستون مجموعه‌داده، تحلیل اکتشافی، تعریف عملیاتی

وضعیت‌های ترکیبی acceptance/trip، پیش‌پردازش و تقسیم داده‌ها را پوشش می‌دهد. بخش ۴-۳ فرمول‌بندی ریاضی مسئله در قالب MDP با تعریف دقیق هر مؤلفه و توجیه معماری $Q(s, a_features)$ ارائه می‌شود. بخش ۵-۳ معماری مدل عامل‌بنیان شامل طراحی عوامل (مسافر، راننده، اعزام‌کننده) با مدل پذیرش راننده گسترش‌یافته، محیط، قوانین تعامل، زمان‌بندی و کالیبراسیون POM-محور را تبیین می‌کند. بخش ۶-۳ معماری الگوریتم DQN شامل ساختار شبکه، فرآیندها و استراتژی‌های آموزش را معرفی می‌نماید. بخش ۷-۳ یکپارچه‌سازی DQN و ABM شامل رابط‌ها، پروتکل ساخت گذار و حلقه آموزش را تشریح می‌کند. بخش ۸-۳ الگوریتم‌های خط‌مبنا و تعریف صریح آزمایش‌های Ablation را ارائه می‌دهد. بخش ۹-۳ طرح ارزیابی، آزمون‌های آماری، محاسبه قدرت آماری و تحلیل حساسیت را مطرح می‌کند. بخش ۱۰-۳ ابزارها و محیط محاسباتی، و بخش ۱۱-۳ جمع‌بندی فصل را شامل می‌شود.

هدف غایی این فصل آن است که یک برنامه‌نویس پایتون ماهر بتواند با خواندن تنها این فصل و دسترسی به مجموعه‌داده، کل سیستم را بدون ابهام بازپیاپی‌سازی کند.

۲-۳ طراحی کلی پژوهش

۱-۲-۳ نوع و فلسفه پژوهش

این پژوهش از نظر فلسفه علم در پارادایم اثبات‌گرایانه (Positivist) جای می‌گیرد؛ زیرا فرض بنیادی آن بر وجود واقعیتی عینی و قابل اندازه‌گیری (عملکرد سیستم تخصیص تاکسی آنلاین) استوار است. این پارادایم با رویکرد «مشاهده ← فرضیه ← آزمون ← نتیجه‌گیری» سازگار است (Saunders et al., 2019). از منظر هدف، پژوهش توسعه‌ای-کاربردی است.

از نظر روش، پژوهش کمی (Quantitative) و آزمایشی (Experimental) است: عملکرد شش الگوریتم تخصیص (شامل سه خط‌مبنا، دو شرط Ablation و مدل پیشنهادی) بر سه شاخص عملکرد (متغیرهای وابسته: WT، CR، DU) تحت سه سناریوی کنترل‌شده مقایسه می‌شود. از منظر گردآوری داده‌ها، پژوهش مبتنی بر دو منبع است: داده‌های ثانویه واقعی (۱۰۴,۷۷۰ رکورد عملیاتی) و داده‌های تولیدشده از شبیه‌سازی عامل‌بنیان کالیبره‌شده. از منظر زمان، پژوهش مقطعی است.

از دیدگاه پیاز پژوهش‌ساز، این تحقیق در شش لایه به‌ترتیب از بیرون به درون عبارت است از: فلسفه اثبات‌گرایانه، رویکرد نظری استقرایی، روش کمی، استراتژی آزمایشی، افق زمانی مقطعی، و گردآوری داده‌های ثانویه. از منظر طبقه‌بندی واکر (Walker, 1998)، روش تحقیق از نوع تحلیلی-ریاضی است.

۲-۲-۳ رویکرد پژوهش: بهینه‌سازی مبتنی بر شبیه‌سازی

رویکرد روش‌شناختی کلان این پژوهش، بهینه‌سازی مبتنی بر شبیه‌سازی (Simulation-Based Optimization; SBO) است. فو (Fu, 2015) این رویکرد را برای مسائلی توصیه می‌کند که تابع هدف آن‌ها به شکل بسته (Closed-Form) در دسترس نیست و ارزیابی هر سیاست تنها از طریق اجرای شبیه‌سازی ممکن است.

در مسئله تخصیص تاکسی آنلاین، تابع هدف (ترکیب وزن دار WT و DU) به عوامل تصادفی متعدد وابسته بوده و مدل سازی تحلیلی آن عملاً ناممکن است.

محیط شبیه سازی عامل بنیان ساخته شده در Mesa نقش «دوقلوی دیجیتال» (Digital Twin) سیستم واقعی تاکسی آنلاین تهران را ایفا می کند. الگوریتم DQN از طریق تعامل مکرر با این محیط، سیاست بهینه تخصیص را به صورت تطبیقی می آموزد.

۳-۲-۳ فرآیند کلی اجرای پژوهش

فرآیند اجرایی پژوهش در دوازده گام طراحی شده است. نسبت به نسخه پروپوزال، دو گام جدید — تثبیت طراحی (گام ۳) و تحلیل حساسیت (گام ۱۱) — به صراحت افزوده شده اند:

گام ۱ — **تعریف مسئله**: فرمول بندی مسئله تخصیص پویای تصادفی در قالب MDP.

گام ۲ — **مرور ادبیات و چارچوب مفهومی**: تکمیل شده در فصول اول و دوم.

گام ۳ — **تثبیت طراحی (Design Freeze)**: تعیین قطعی ۳۲ مؤلفه بردار حالت، معماری $Q(s, a_{features})$ برای فضای اقدام، تابع پاداش با جریمه رد، و فرایارامترهای DQN.

گام ۴ — **جمع آوری و پیش پردازش داده ها**: دریافت ۱۰۴,۷۷۰ رکورد، تمیز سازی، تعریف عملیاتی وضعیت های ترکیبی acceptance/trip، مهندسی ویژگی و نرمال سازی.

گام ۵ — **پیاده سازی محیط ABM**: ساخت مدل عامل بنیان در Mesa با مدل پذیرش راننده گسترش یافته.

گام ۶ — **کالیبراسیون POM-محور**: باز تولید شش الگوی سبک شده مشاهده شده در داده های واقعی.

گام ۷ — **پیاده سازی الگوریتم DQN**: ساخت شبکه $Q(s, a_{features})$ در PyTorch.

گام ۸ — **یکپارچه سازی DQN و ABM**: اتصال رابطها با پروتکل ساخت گذار صریح.

گام ۹ — **آموزش مدل**: اجرای ۱۰۰۰ اپیزود آموزشی با (early stopping (patience=۵۰).

گام ۱۰ — **ارزیابی Baseline و Ablation**: مقایسه آماری با سه خطمبنا (Random، Greedy، Hungarian) و دو شرط (Ablation (DQN-only، ABM-only).

گام ۱۱ — **تحلیل حساسیت**: بررسی پایداری سیاست در برابر تغییر ضرایب پاداش و فرایارامترهای DQN.

گام ۱۲ — **تحلیل نتایج**: ارائه تفسیر یافته ها در فصل های چهارم و پنجم.

۳-۳ داده های پژوهش

۱-۳-۳ منبع و توصیف داده ها

داده های مورد استفاده در این پژوهش، از یک شرکت فعال در حوزه خدمات تاکسی آنلاین در شهر تهران دریافت شده است. مجموعه داده شامل ۱۰۴,۷۷۰ رکورد درخواست سفر است که در بازه زمانی ۳۰ روزه فروردین ماه ۱۴۰۳

(مارس-آوریل ۲۰۲۴) ثبت شده‌اند. این داده‌ها فعالیت تقریباً ۸۰۰ راننده فعال را در ۱۴ ناحیه جغرافیایی شهر تهران پوشش می‌دهد. هر رکورد شامل ۳۶ ستون اطلاعاتی است که در پنج گروه اصلی دسته‌بندی می‌شوند:

- اطلاعات شناسایی و زمانی (request_id, timestamp, date, shamsi_day, hour_of_day, minute_of_hour, day_of_week, day_name, is_weekend, is_peak_hour, time_bin (hour_sin, hour_cos, dow_sin, dow_cos)
- اطلاعات مکانی (passenger_lat, passenger_lon, destination_lat, destination_lon, trip_distance_km, driver_id, driver_lat, driver_lon (driver_distance_to_passenger_km
- اطلاعات عملیاتی (acceptance_status, trip_status, waiting_time_min (trip_duration_min, fare_toman, waiting_time_normalized, driver_utilization_rate
- متغیرهای محیطی و بازاری (surge_multiplier, demand_supply_index, weather_condition (n_active_drivers, patience_min

۲.۳.۳ تعریف عملیاتی وضعیت‌های ترکیبی

نکته روش‌شناختی مهم: بازرسی اولیه داده‌ها نشان می‌دهد که فیلدهای acceptance_status و trip_status می‌توانند ترکیب‌های متنوعی داشته باشند. برای رفع ابهام در مدل‌سازی و کالیبراسیون ABM، تمامی ترکیب‌های مشاهده‌شده در جدول ۱-۳ به‌طور صریح تعریف می‌شوند:

جدول ۱-۳. تعریف عملیاتی ترکیب‌های (acceptance_status, trip_status) و معنای رفتاری آن‌ها

acceptance_status	trip_status	تفسیر رفتاری	اقدام در ABM
accepted	completed	تخصیص موفق، سفر کامل	trip تکمیل و در CR محاسبه
accepted	cancelled_by_passenger	تخصیص اولیه، اما مسافر قبل از پیکاپ لغو کرد	trip ناتمام، در CR محاسبه نمی‌شود
accepted	cancelled_by_driver	تخصیص اولیه، اما راننده پس از پذیرش لغو کرد	trip ناتمام، شمارش جداگانه
rejected	no_driver	همه رانندگان کاندید رد کردند یا کاندیدی یافت نشد	ناکامی تخصیص، تأثیر منفی بر CR
rejected	expired	زمان انتظار از patience مسافر گذشت	لغو مسافر، تأثیر منفی بر CR

این تعریف صریح، در ABM به‌عنوان مرجع ساخت رویدادها و در مرحله کالیبراسیون به‌عنوان معیار اعتبارسنجی استفاده می‌شود.

۳.۳.۳ تحلیل اکتشافی داده‌ها (EDA)

تحلیل اکتشافی داده‌ها در پنج محور انجام شده است. خلاصه شاخص‌های کلیدی در جدول ۲-۳ ارائه می‌شود؛ تحلیل تفصیلی همراه با توزیع‌ها و الگوهای زمانی-مکانی در فصل چهارم (بخش EDA) آورده خواهد شد:

جدول ۲-۳. خلاصه شاخص‌های کلیدی مجموعه داده

ملاحظه	مقدار	شاخص
بازه ۳۰ روزه فروردین ۱۴۰۳	۱۰۴,۷۷۰	تعداد کل درخواست‌ها
نرخ تکمیل: ۶۱.۵۴٪	۶۴,۴۷۱	تعداد سفرهای تکمیل‌شده
معیار کالیبراسیون POM	۲۶.۰٪	نرخ لغو توسط مسافر
معیار کالیبراسیون POM	۱۲.۵٪	نرخ عدم یافتن راننده
انحراف معیار: ۱.۸۶ دقیقه	۲.۵۱ دقیقه	میانگین زمان انتظار (WT)
محدوده روزانه: ۶۲.۲٪ تا ۶۴.۱٪	۶۳.۶۴٪	میانگین بهروری راننده (DU)
میان: ۴۰.۷۲؛ صدک ۹۵: ۱.۸۱	۰.۸۳ کیلومتر	میانگین فاصله راننده-مسافر
الگوی دو-قله صبح-عصر	۳۳.۱ برابر	نسبت تقاضای اوج به کف
ضریب تغییرات ۷۴٪	۳۶۸ تا ۶۴۰	تعداد رانندگان فعال در نوسان
معیار کالیبراسیون POM	۳۹.۷+٪	افزایش WT در باران سنگین

۴-۳-۳ پیش‌پردازش داده‌ها

پیش‌پردازش داده‌ها در شش گام صورت می‌گیرد:

(۱) رفع داده‌های گمشده: فیلدهای waiting_time_min و trip_duration_min و fare_toman در رکوردهای با trip_status ∈ {no_driver, expired, cancelled_by_passenger} به‌طور طبیعی خالی هستند؛ این موارد به‌عنوان داده گمشده تلقی نمی‌شوند بلکه با شاخص دلالت‌گر (Indicator) جداگانه نشانه‌گذاری می‌شوند. فیلدهای دیگر در صورت داشتن مقدار گمشده با imputation متناسب نوع (میان‌ه برای پیوسته، mode برای طبقه‌ای) جایگزین می‌شوند.

(۲) رفع داده‌های پرت (Outlier): رکوردهای با waiting_time_min > ۳۰ دقیقه یا trip_distance_km < ۵۰ کیلومتر یا fare_toman > ۵۰۰,۰۰۰ به‌عنوان موارد غیرعادی نشانه‌گذاری و در آموزش حذف می‌شوند (در مجموع کمتر از ۰.۵٪ داده‌ها).

(۳) مهندسی ویژگی: متغیرهای زمانی به فرم سینوسی-کسینوسی (روابط ۱-۳ و ۲-۳) برای حفظ خاصیت دوره‌ای؛ متغیرهای طبقه‌ای (weather_condition, day_name) با one-hot encoding تبدیل می‌شوند.

$$\text{hour_sin} = \sin(2\pi \cdot \text{hour_of_day} / 24) \quad (31-)$$

$$\text{hour_cos} = \cos(2\pi \cdot \text{hour_of_day} / 24) \quad (32-)$$

(۴) نرمال‌سازی: متغیرهای پیوسته با Min-Max scaling به بازه [۰, ۱] نرمال می‌شوند. پارامترهای نرمال‌سازی (min, max) از داده‌های آموزش محاسبه و در ارزیابی نیز همان مقادیر اعمال می‌شوند (برای جلوگیری از data leakage).

(۵) تقسیم داده‌ها: از تقسیم زمانی (Temporal Split) استفاده می‌شود تا غیرایستایی (Non-Stationarity) داده‌ها حفظ شود. روزهای ۱-۲۰ (۷۰٪) برای آموزش، روزهای ۲۱-۲۵ (۱۵٪) برای اعتبارسنجی

فرایارامترها، و روزهای ۲۶-۳۰ (≈۱۵٪) برای ارزیابی نهایی نگه داشته می‌شوند. آرلو و سلیس (Arlot & Celisse, 2010) نشان داده‌اند که تقسیم تصادفی در داده‌های سری زمانی موجب نشت اطلاعات (Information Leakage) می‌گردد و باید اجتناب شود.

۶) **استخراج توزیع‌های مولد:** از داده‌های آموزش، توزیع‌های زیر به‌عنوان ورودی ABM استخراج می‌شوند: نرخ ورود درخواست پواسون ($zone \times hour$)، توزیع max_wait مسافر (نمایی)، ماتریس‌های فاصله و زمان سفر بین نواحی، توزیع شرایط جوی، و توزیع فعالیت رانندگان.

۴-۳ فرمول‌بندی ریاضی مسئله

۱-۴-۳ تعریف رسمی مسئله تخصیص پویای تصادفی

مسئله تخصیص کلاسیک (که در بخش ۲-۲ به تفصیل تشریح شد) فرض می‌کند مجموعه ثابتی از منابع و وظایف وجود دارد و یک تابع هزینه قطعی روی هر زوج تعریف شده است. در صنعت تاکسی آنلاین، سه تعمیم بنیادین لازم است که این مسئله را به‌کلی متفاوت می‌سازد: پویایی (مجموعه‌های D_t و P_t در طول زمان تغییر می‌کنند)، تصادفی بودن (ورود درخواست‌ها، رفتار رانندگان و شرایط محیطی همگی تصادفی‌اند)، و چندهدفه بودن (همزمان DU و WT باید بهینه شوند). بر اساس داده‌های این پژوهش، میانگین تعداد رانندگان فعال از ۳۶۸ در ساعت ۳ بامداد تا ۶۴۰ در ساعت ۱۷ نوسان دارد.

با توجه به این سه تعمیم، مسئله تخصیص پویای تصادفی به‌صورت زیر فرمول‌بندی می‌شود:

$$\pi^* = \operatorname{argmax}_{\pi} E_{\pi} [\sum_{t=0}^T \gamma^t R_t] \quad (33-)$$

که در آن π سیاست تخصیص (نگاشت حالت به اقدام)، R_t پاداش گام t (که در ادامه تعریف می‌شود)، γ ضریب تنزیل، T افق زمانی، و امید ریاضی روی تصادفی بودن محیط گرفته شده است. حل مستقیم این مسئله به‌دلیل ابعاد بالای فضای حالت و ماهیت تصادفی تابع هدف امکان‌پذیر نیست و بنابراین فرمول‌بندی آن در قالب فرآیند تصمیم مارکوف ضروری است.

۲-۴-۳ فرمول‌بندی فرآیند تصمیم مارکوف (MDP)

با توجه به مبانی نظری MDP ارائه‌شده در بخش ۱-۳-۲ (تعریف تاپل $\langle S, A, P, R, \gamma \rangle$ و معادلات بلمن)، در ادامه هر مؤلفه MDP به‌طور خاص برای مسئله تخصیص تاکسی آنلاین تهران تعریف عملیاتی می‌شود.

الف) فضای حالت S : بردار حالت ۳۲ بُعدی

بردار حالت $s_t \in \mathbb{R}^{32}$ در هر گام زمانی t وضعیت کلی سیستم را توصیف می‌کند. این بردار از ۱۴ مؤلفه اصلی تشکیل شده که مجموعاً ۳۲ بُعد عددی ایجاد می‌کنند. جدول ۳-۳ هر مؤلفه را با جزئیات معرفی می‌کند.

جدول ۳-۳. مؤلفه‌های بردار حالت، ابعاد و دامنه مقادیر

مؤلفه	توضیح	بُعد	دامنه
hour_sin, hour_cos	نمایش دوره‌ای ساعت روز	۲	[۱, -۱]

day_sin, day_cos	نمایش دوره‌ای روز هفته	۲	[۱, -۱]
zone_id (one-hot)	ناحیه جغرافیایی فعلی پنجره تصمیم	۱۴	{۱, ۰}
demand_supply_index	نسبت تقاضا به عرضه در ناحیه فعلی	۱	[۱, ۰]
surge_multiplier	ضریب افزایش قیمت پویا	۱	[۱, ۰]
weather (one-hot)	شرایط جوی: clear/cloudy/rainy/heavy_rain	۴	{۱, ۰}
mean_WT_zone	میانگین WT در ناحیه در ۱۰ دقیقه اخیر	۱	[۱, ۰]
n_available_drivers	رانندگان در دسترس ناحیه (نرمال)	۱	[۱, ۰]
n_pending_requests	درخواست‌های معلق ناحیه (نرمال)	۱	[۱, ۰]
mean_pickup_dist	میانگین فاصله پیکاپ اخیر ناحیه	۱	[۱, ۰]
DU_zone	نرخ بهر‌موری رانندگان ناحیه	۱	[۱, ۰]
is_weekend	پرچم آخر هفته	۱	{۱, ۰}
is_holiday	پرچم تعطیلات رسمی	۱	{۱, ۰}
is_rush_hour	پرچم ساعت اوج	۱	{۱, ۰}
جمع (d_s)	ابعاد کل بردار حالت	۳۲	—

توضیح روش‌شناختی: مؤلفه zone_id با کدگذاری one-hot نمایش داده می‌شود زیرا نواحی فاقد ترتیب طبیعی هستند. سه مؤلفه (mean_pickup_dist، n_pending_requests، n_available_drivers) به ناحیه فعلی پنجره تصمیم محدود می‌شوند، که در بخش ۳-۷ تشریح می‌شود. متغیرهای زمانی (day_sin/cos، hour_sin/cos) به فرم سینوسی-کسینوسی نمایش داده می‌شوند تا خاصیت دوره‌ای زمان حفظ شود — برای مثال، ساعت ۲۳ و ساعت ۰ به‌جای فاصله ۲۳، فاصله نزدیک به ۱ دارند که با واقعیت سازگار است.

بازنمایی حالت (State Representation): ساتون و بارتو (Sutton & Barto, 2018) تأکید کرده‌اند که بازنمایی مناسب حالت، یکی از عوامل تعیین‌کننده موفقیت الگوریتم‌های RL است. در طراحی فعلی، اطلاعات کافی (Sufficiency) برای ارضای تقریبی خاصیت مارکوف از طریق گنجاندن متغیرهای بافتاری (آب‌وهوا، ساعت، نسبت عرضه/تقاضا) فراهم شده است؛ این انتخاب، در شکاف ۴ فصل دوم به‌عنوان پاسخی به ضعف ادبیات قبلی موقعیتیابی شد.

ب) فضای اقدام A: معماری Q(s, a_features) برای تخصیص ناوردا

نکته مهم روش‌شناختی: در نسخه‌های اولیه طراحی، فضای اقدام به‌صورت یک خروجی Top-K (مثلاً K=۵۰) تعریف شده بود که در آن هر شاخص خروجی به یک «رتبه» در لیست مرتب‌شده کاندیدها اشاره می‌کرد. این رویکرد دو ضعف بنیادی داشت: نخست، نسبت به جابه‌جایی ترتیب کاندیدها وابسته است (Permutation-Dependent) — یعنی اگر دو کاندید دارای ویژگی‌های مشابه باشند، ترتیب آن‌ها در ورودی به نتیجه نهایی تأثیر می‌گذارد؛ دوم، اگر تعداد کاندیدها کمتر از K باشد، خروجی‌های اضافی بی‌معنا می‌شوند و نیاز به ماسک‌گذاری دستی دارند.

بنابراین در نسخه نهایی، معماری به Q(s, a_features) تغییر یافته است. در این رویکرد:

- شبکه عصبی به جای K خروجی، یک Q -value اسکالر تولید می‌کند.
- ورودی شبکه شامل دو بخش است: بردار حالت سراسری $s \in \mathbb{R}^{32}$ و بردار ویژگی‌های جفت کاندید $a_features \in \mathbb{R}^8$.
- در هر گام تصمیم، شبکه برای هر جفت کاندید $(driver, passenger)$ یکبار اجرا می‌شود و جفت با بالاترین Q انتخاب می‌گردد.
- این معماری ذاتاً ناوردا (Permutation-Invariant) است و نیازی به ماسک‌گذاری ندارد؛ همچنین می‌تواند با تعداد کاندید متغیر کار کند.
- بردار ویژگی‌های جفت کاندید $a_features \in \mathbb{R}^8$ شامل ۸ ویژگی است که هر زوج $(driver, passenger)$ را توصیف می‌کنند:

جدول ۴-۳. مؤلفه‌های بردار ویژگی جفت کاندید ($a_features$)

ویژگی	توضیح	دامنه
pickup_distance	فاصله راننده تا مسافر (کیلومتر، نرمال)	$[1, 0]$
trip_distance	فاصله سفر مسافر (کیلومتر، نرمال)	$[1, 0]$
estimated_eta	زمان تخمینی رسیدن (دقیقه، نرمال)	$[1, 0]$
driver_acceptance_rate	نرخ پایه پذیرش این راننده	$[1, 0]$
driver_utilization_so_far	بهرموری راننده تا این لحظه در شیفت	$[1, 0]$
destination_zone_attractiveness	جذابیت مقصد (تقاضای آینده مقصد)	$[1, 0]$
passenger_wait_so_far	زمان انتظار مسافر تاکنون (دقیقه، نرمال)	$[1, 0]$
fare_estimate	کرایه تخمینی (نرمال)	$[1, 0]$

مجموع ابعاد ورودی شبکه $d_in = d_s + d_a = 32 + 8 = 40$ است. خروجی شبکه یک اسکالر $Q(s, a_features)$ است که برای هر کاندید جداگانه محاسبه می‌شود.

توجیه ادبیاتی: این معماری در ادبیات RL با نام «Q-network with action features» شناخته می‌شود و در مطالعاتی همچون (Tang et al. (2019, KDD) برای مسئله dispatch تاکسی استفاده شده است. مزیت آن نسبت به Pointer Networks (Vinyals et al., 2015) سادگی پیاده‌سازی و قابلیت دفاع روش‌شناختی بالاتر است.

ج) تابع پاداش R

تابع پاداش به‌صورت ترکیبی وزن‌دار طراحی شده تا چندهدفه بودن مسئله را پوشش دهد:

$$R_t = -\alpha \cdot (WT_t / WT_baseline) + \beta \cdot (DU_t / DU_baseline) - \lambda \cdot 1[reject_t] \quad (34-)$$

که در آن:

• WT_t میانگین زمان انتظار مسافران تخصیص‌یافته در گام t (دقیقه)

• DU_t نرخ بهرموری رانندگان در گام t

• $WT_baseline = ۲.۵۱$ دقیقه (مقدار میانگین داده واقعی)

• $DU_baseline = ۰.۶۳۶۴$ (مقدار میانگین داده واقعی)

• $1[reject_t]$ تابع شاخص: ۱ اگر راننده اقدام پیشنهادی را رد کند، ۰ در غیر این صورت

• $\alpha = ۰.۶$ ، $\beta = ۰.۴$ ، $\lambda = ۰.۲$ ضرایب وزن‌دهی

توجیه ضرایب: انتخاب $\alpha > \beta$ نشان‌دهنده اولویت زمان انتظار مسافر بر بهرهوری راننده است. این انتخاب بر اساس مطالعات روان‌سنجی (که حساسیت بیشتر مسافران به انتظار را نسبت به حساسیت رانندگان به بیکاری نشان می‌دهند) و همچنین این واقعیت که در یک بازار دوطرفه، نرخ ترک پلتفرم توسط مسافر معمولاً بیشتر از راننده است، صورت گرفته. ضریب $\lambda = ۰.۲$ به‌عنوان جریمه ساختاری برای انتخاب‌های ردشده طراحی شده تا عامل DQN از پیشنهادهایی که احتمالاً رد می‌شوند پرهیز کند. حساسیت این ضرایب در تحلیل بخش ۳-۵ به‌صراحت بررسی می‌شود. ویژگی‌های طراحی پاداش: (۱) اسکالر و سازگار با چارچوب استاندارد RL؛ (۲) محاسبه در هر گام (نه پراکنده) که مسئله Sparse Reward را برطرف می‌کند؛ (۳) نرمال‌شده نسبت به مقادیر پایه که قابلیت تعمیم به بازارهای دیگر را افزایش می‌دهد.

د) ضریب تنزیل و افق زمانی

ضریب تنزیل $\gamma = ۰.۹۵$ انتخاب شده که نشان‌دهنده اهمیت متوسط پاداش‌های آینده است. این مقدار توازن مناسبی بین سیاست‌های لحظه‌ای ($\gamma \rightarrow ۰$) و آینده‌نگر ($\gamma \rightarrow ۱$) برقرار می‌کند. افق زمانی هر اپیزود $T = ۷۲۰$ گام (یک روز کامل با گام‌های ۲ دقیقه‌ای) تنظیم شده است.

۵-۳ معماری مدل عامل‌بنیان

۱-۵-۳ طراحی عوامل

الف) عامل مسافر (PassengerAgent)

هر عامل مسافر نماینده فردی است که درخواست سفر ثبت کرده است. جدول ۳-۵ ویژگی‌ها و رفتارهای این عامل را تشریح می‌کند.

جدول ۳-۵. ویژگی‌ها و رفتارهای عامل مسافر

منبع / مقداردهی	توضیح	ویژگی / رفتار
از رکوردهای واقعی	مختصات جغرافیایی مبدأ	origin_lat, origin_lng
از رکوردهای واقعی	مختصات جغرافیایی مقصد	dest_lat, dest_lng
از timestamp	زمان ثبت درخواست	request_time
Exponential($\lambda=۱/۴$)، میانگین=۴	حداکثر زمان انتظار قابل تحمل (دقیقه)	max_wait
Uniform(۰, ۱)	حساسیت قیمتی مسافر	price_sensitivity
waiting→assigned→in_trip→completed cancelled	وضعیت	status

Request رفتار	ثبت درخواست بر اساس توزیع زمانی-مکانی	—
Wait رفتار	انتظار، افزایش شمارنده زمان	—
Cancel رفتار	لغو اگر $wait_time > max_wait$ با $p=0.7$	—

توزیع نمایی با میانگین ۴ دقیقه برای max_wait بر اساس تحلیل الگوی لغو در داده‌های واقعی تعیین شده است: ۷۲٪ لغوها در ۲ دقیقه نخست و ۹۱٪ در ۵ دقیقه نخست رخ می‌دهند که با توزیع نمایی سازگار است. مقدار $p_cancel = 0.7$ از برازش منحنی لغو بر داده‌های واقعی به‌دست آمده.

ب) عامل راننده (DriverAgent)

جدول ۶-۳ ویژگی‌ها و رفتارهای عامل راننده را تشریح می‌کند.

جدول ۶-۳. ویژگی‌ها و رفتارهای عامل راننده

منبع / مقداردهی	توضیح	ویژگی / رفتار
از داده‌های واقعی	شناسه یکتای راننده	driver_id
به‌روزرسانی در هر گام	مکان فعلی	lat, lng
available en_route busy offline	وضعیت	status
$Beta(8, 2)$ ، میانگین=۰.۸	نرخ پایه پذیرش	acceptance_rate
Uniform(۰, ۱)	گریز از مقصدهای کم‌تقاضا	destination_aversion
Uniform(۰, ۱)	گریز از سفرهای کوتاه	short_trip_aversion
از خوشه‌بندی داده‌ها	ناحیه ترجیحی	zone_preference
از توزیع مشاهده‌شده	ساعت شیفت	shift_start, shift_end
رابطه ۵-۳ (گسترش‌یافته)	تصمیم پذیرش/رد	Accept/Reject رفتار
سرعت مبتنی بر ترافیک	حرکت به مبدأ مسافر	Navigate رفتار
از trip_duration_min	حمل مسافر	Transport رفتار
—	بیکاری و حرکت تصادفی	Idle رفتار

مدل پذیرش راننده گسترش‌یافته

در نسخه‌های اولیه، مدل پذیرش راننده تنها سه عامل (نرخ پایه، فاصله، ضریب سرج) را در نظر می‌گرفت. این مدل با شواهد فصل اول ناسازگار بود — جایی که مشاهده شده «رانندگان مسیرهایی که آن‌ها را به مناطق کم‌تقاضا می‌برد را اغلب رد می‌کنند» و «سفرهای خیلی کوتاه را به دلیل کم‌سیون پایین رد می‌کنند». بنابراین در نسخه نهایی، مدل پذیرش به دو عامل اضافی گسترش یافته است:

$$p_{accept}(d, r) = AR_d \cdot f_{dist}(d, r) \cdot f_{surge}(r) \cdot f_{dest}(d, r) \cdot f_{length}(d, r) \quad (35)$$

که در آن:

$$f_{dist}(d, r) = \max(0, 1 - pickup_dist / d_{max}) \quad (35-f)$$

$$f_surge(r) = 0.5 + 0.5 \cdot surge_multiplier_normalized \quad (5-3)$$

$$f_dest(d,r) = 1 - \delta_d \cdot (1 - zone_attractiveness(dest_zone)) \quad (5-3)$$

$$f_length(d,r) = 1 - \sigma_d \cdot \mathbb{1}[trip_distance < 2 \text{ km}] \quad (5-3)$$

که AR_d نرخ پایه پذیرش راننده (از $(\beta, 2)$ ، $d_max = 5$ کیلومتر، $\delta_d =$ $zone_attractiveness(z)$ عامل، $\sigma_d = short_trip_aversion$ عامل، و $zone_attractiveness(z)$ شاخصی بین ۰ و ۱ است که تقاضای پیش‌بینی‌شده ناحیه z را در ۳۰ دقیقه آینده نشان می‌دهد (از توزیع زمانی-مکانی استخراج‌شده). این مدل گسترش‌یافته، چهار واقعیت رفتاری را مدل می‌سازد: ناهمگنی رانندگان، اثر فاصله، اثر انگیزه قیمتی، اثر کیفیت مقصد و اثر طول سفر.

ج) عامل اعزام‌کننده (DispatcherAgent)

عامل اعزام‌کننده تنها عامل مبتنی بر DQN بوده و سیاست تخصیص را اجرا می‌کند. در هر گام زمانی، این عامل: (۱) بردار حالت سراسری $s_t \in \mathbb{R}^{32}$ را از محیط ABM استخراج می‌کند؛ (۲) برای هر جفت کاندید $(driver_i, passenger_j)$ بردار ویژگی $a_features \in \mathbb{R}^8$ را محاسبه می‌کند؛ (۳) $Q(s_t)$ ، $a_features$ را از شبکه عصبی محاسبه می‌کند؛ (۴) جفت با بالاترین Q (یا یک جفت تصادفی با احتمال ϵ در سیاست ϵ -greedy) را انتخاب می‌کند؛ (۵) دستور تخصیص را به محیط ABM صادر می‌نماید. در الگوریتم‌های خطمبنا، همین عامل از قوانین ثابت متناظر استفاده می‌کند.

۲-۵-۳ طراحی محیط: ۱۴ ناحیه تهران

محیط شبیه‌سازی شامل ۱۴ ناحیه جغرافیایی شهر تهران است که تقسیم‌بندی آن از شرکت تأمین‌کننده داده دریافت شده. برای هر جفت ناحیه (i, j) ، دو ماتریس 14×14 از داده‌های واقعی استخراج شده‌اند: ماتریس فاصله $\exists D \in \mathbb{R}^{14 \times 14}$ (کیلومتر) و ماتریس زمان سفر $T \in \mathbb{R}^{14 \times 14}$ (دقیقه در شرایط ترافیکی عادی).

مدل ترافیک: سرعت متوسط با ضرایب ساعت‌محور تنظیم می‌شود. در ساعات اوج (۷-۹ و ۱۷-۲۰)، زمان سفر ۴۰٪ افزایش (ضریب ۱.۴) و در ساعات خلوت (۲۲-۶)، ۲۰٪ کاهش (ضریب ۰.۸) می‌یابد.

مدل آب‌وهوا: چهار وضعیت جوی (clear، cloudy، rainy، heavy_rain) بر اساس توزیع مشاهده‌شده در داده‌ها نمونه‌برداری می‌شود. در بارندگی سنگین: سرعت ترافیک ۳۰٪ کاهش (ضریب ۱.۴۳ بر زمان سفر)، تقاضا ۲۰٪ افزایش و تعداد رانندگان فعال ۱۰٪ کاهش می‌یابد.

مدل تولید تقاضا: درخواست‌ها بر اساس فرآیند پواسون ناهمگن (Non-Homogeneous Poisson Process) تولید می‌شوند که نرخ آن $\lambda(zone, hour, weather)$ از داده‌های آموزش به‌صورت تجربی استخراج می‌گردد.

۳-۵-۳ قوانین تعامل

چرخه تعامل اصلی در هر گام ۲ دقیقه‌ای شبیه‌سازی بدین شرح است:

(1) تولید درخواست‌های جدید بر اساس فرآیند پواسون ناهمگن

(2) بررسی مسافران منتظر و اعمال قانون لغو (اگر $\text{wait_time} > \text{max_wait}$)

(3) ساخت ماتریس کاندیدهای راننده-مسافر (رانندگان در دسترس در شعاع $d_max = 5$ کیلومتر)

(4) اتخاذ تصمیم تخصیص توسط DispatcherAgent (DQN یا خطمبنا)

(5) تصمیم پذیرش/رد توسط هر راننده بر اساس رابطه ۵-۳

(6) در صورت پذیرش: راننده $\rightarrow \text{en_route}$ ، شروع حرکت به مبدأ

(7) در صورت رد: درخواست به صف برمی‌گردد، تلاش مجدد در گام بعد

(8) به‌روزرسانی موقعیت رانندگان در حال حرکت/سفر

(9) محاسبه شاخص‌های CR، DU، WT و ثبت در DataCollector

۴-۵-۳ زمان‌بندی

از زمان‌بند RandomActivation کتابخانه (Kazil et al., 2020) Mesa استفاده می‌شود. در هر گام زمانی، عوامل به ترتیب تصادفی فعال می‌شوند. این انتخاب از سوگیری ناشی از ترتیب ثابت جلوگیری می‌کند (Masad & Kazil, 2015).

۵-۵-۳ کالیبراسیون POM-محور

کالیبراسیون مدل ABM با رویکرد مدل‌سازی الگومحور (Pattern-Oriented Modelling; POM) گریم و همکاران (Grimm et al., 2005) انجام می‌شود. این رویکرد به‌جای تطبیق با یک شاخص کلان، نیازمند بازتولید همزمان چندین الگوی مشاهده‌شده در سطوح مختلف است. شش الگوی کالیبراسیون به‌عنوان معیار سنجش عبارتند از:

الگو	مقدار هدف	خطای پذیرفته
نرخ تکمیل سفر (CR)	۶۱.۵۴٪	۳±٪
میانگین زمان انتظار (WT)	۲.۵۱ دقیقه	۰.۳± دقیقه
نرخ بهرهوری راننده (DU)	۶۳.۶۴٪	۳±٪
نرخ لغو مسافر	۲۶٪	۲±٪
نرخ عدم یافتن راننده	۱۲.۵٪	۲±٪
افزایش WT در باران سنگین	۳۹.۷+	۵±٪

فرآیند کالیبراسیون: اجرای ۱۰ شبیه‌سازی با پارامترهای فعلی، مقایسه خروجی‌ها با ۶ معیار، تنظیم پارامترها و تکرار تا رسیدن به بازه‌های مجاز در همه ۶ معیار. اگر ۶ الگو همزمان بازتولید شوند، می‌توان با اطمینان بالایی ادعا کرد که مدل، مکانیزم‌های مولد واقعی را به‌درستی شبیه‌سازی می‌کند.

۶-۵-۳ پیاده‌سازی در Mesa

ساختار کد شامل چهار کلاس اصلی است: PassengerAgent، DriverAgent، DispatcherAgent و RideHailingModel(mesa.Model). محیط Gymnasium به صورت Wrapper حول RideHailingModel ساخته می‌شود تا با Stable-Baselines3 سازگار باشد.

الگوریتم ۱. شبیه‌سازی یک گام ABM با تخصیص دسته‌ای

```
procedure ABM_STEP(model, t):
    // 1. Generate new passenger requests
    rate <- poisson_rate(zone, hour, weather)
    n_new <- Poisson(rate × delta_t)
    for i = 1 to n_new:
        record <- sample_from_data(train_data, zone, hour)
        pax <- PassengerAgent(origin, dest, max_wait~Exp(1/4), p_sens~U(0,1))
        model.schedule.add(pax)

    // 2. Handle cancellations
    for each pax in model.waiting_passengers:
        if pax.wait_time > pax.max_wait and random() < 0.7:
            pax.status <- CANCELLED

    // 3. Build candidate matrix
    pending <- [p for p in passengers if p.status == WAITING]
    available <- [d for d in drivers if d.status == AVAILABLE]
    candidates <- [(d, p, dist(d.loc, p.origin)) for (d,p) in available × pending
                    if dist(d.loc, p.origin) <= 5 km]

    // 4. Sequential assignment with state refresh (see Section 3-7-2)
    s_t <- model.get_state_vector() // shape (32,)
    while candidates is not empty:
        // Compute Q for each candidate
        Q_values <- []
        for each (d, p, dist) in candidates:
            a_feat <- compute_action_features(d, p, model) // shape (8,)
            q <- DQN.forward(s_t, a_feat)
            Q_values.append(q)
        a_idx <- argmax(Q_values) // or random with prob epsilon
        (d_chosen, p_chosen, _) <- candidates[a_idx]
        a_feat_chosen <- compute_action_features(d_chosen, p_chosen, model)

        // Driver accept/reject (Equation 3-5)
        p_acc <- compute_acceptance_probability(d_chosen, p_chosen, model)
        if random() < p_acc:
            d_chosen.status <- EN_ROUTE; d_chosen.target <- p_chosen
            p_chosen.status <- ASSIGNED
            reject_flag <- 0
        else:
            p_chosen.reject_count += 1
```

```

reject_flag <- 1

// Compute step reward for this transition
r_step <- compute_partial_reward(d_chosen, p_chosen, reject_flag)

// Remove pairs containing d_chosen or p_chosen from candidates
candidates <- filter_out(candidates, d_chosen, p_chosen)
s_t <- model.get_state_vector() // refresh state for next sub-step

// Store transition (see Section 3-7-2 for protocol)
store_transition(s_prev, a_feat_chosen, r_step, s_t, done)

// 5. Advance trips and compute global metrics
for each driver in en_route or busy:
    driver.advance(delta_t=2 min, traffic_factor)

// 6. Compute step-level KPIs
WT_t <- mean([p.wait_time for p served this step])
DU_t <- sum(active_time) / sum(available_time)
CR_t <- n_completed_so_far / n_total_so_far
R_t_global <- -0.6 * (WT_t/2.51) + 0.4 * (DU_t/0.6364) // for logging

model.datacollector.collect(WT_t, DU_t, CR_t, R_t_global)
return done = (t == T)

```

۶-۳ معماری الگوریتم DQN

۱-۶-۳ ساختار شبکه عصبی

بر اساس انتخاب معماری $Q(s, a; \theta)$ که در بخش ۲-۴-۳ تبیین شده، شبکه عصبی $Q(s, a; \theta)$ به صورت زیر طراحی شده است:

- لایه ورودی: $d_{in} = d_s + d_a = ۳۲ + ۸ = ۴۰$ (batch_size, ۴۰) شکل ورودی هر نمونه:
- لایه پنهان ۱: ۲۵۶ نورون، فعال‌سازی ReLU
- لایه پنهان ۲: ۲۵۶ نورون، فعال‌سازی ReLU
- لایه پنهان ۳: ۱۲۸ نورون، فعال‌سازی ReLU
- لایه خروجی: ۱ نورون (Q-value اسکالر)، بدون فعال‌سازی (خطی)

توجیه ساختار: استفاده از ۳ لایه پنهان به جای ۲ لایه استاندارد در DQN اصلی (Mnih et al. (2015) به دلیل ناهمگنی ورودی (ترکیب باینری، one-hot و پیوسته) است. اضافه کردن لایه سوم با ابعاد کاهنده (۲۵۶ → ۱۲۸) قابلیت یادگیری نگاشت‌های غیرخطی بین ویژگی‌ها را بدون افزایش بیش از حد پارامترها فراهم می‌کند. مجموع پارامترهای قابل آموزش حدود ۱۲۸,۰۰۰ پارامتر است.

۲-۶-۳ فرایارامترها

فرایارامترهای DQN در جدول ۷-۳ ارائه شده‌اند. این مقادیر بر اساس مرور ادبیات و آزمایش‌های اولیه روی validation set انتخاب شده‌اند:

جدول ۷-۳. فرایارامترهای آموزش DQN

فرایارامتر	مقدار	توجیه
نرخ یادگیری (lr)	۰.۰۰۰۵	۲.۵e-۴؛ Mnih et al. (2015)؛ مقدار محافظه‌کارانه‌تر برای پایداری
اندازه بچ (batch_size)	۶۴	تعادل بین تنوع و کارایی محاسباتی
اندازه بافر تجربه	۱۰۰,۰۰۰	Mnih et al. (2015) و Lin (1992)
گام شروع آموزش	۵,۰۰۰	پر شدن اولیه بافر قبل از آموزش
به‌روزرسانی شبکه هدف	هر ۱,۰۰۰ گام	Mnih et al. (2015)
ضریب تنزیل (γ)	۰.۹۵	افق متوسط، توضیح در ۳-۴-۲-د
ε شروع	۱.۰	اکتشاف کامل در ابتدا
ε پایانی	۰.۰۵	اکتشاف بقایایی
گام‌های زوال ε	۲۰۰,۰۰۰	≈ ۳۰٪ از مجموع گام‌ها
تابع خطا	Huber Loss	مقاوم در برابر outliers (van Hasselt et al., 2016)
بهینه‌ساز	Adam	Kingma & Ba (2015)
تعداد اپیزود	۱,۰۰۰ (با early stopping)	گسترش از ۵۰۰ برای پایداری بیشتر
معیار توقف زودهنگام	patience = ۵۰ اپیزود	بر اساس میانگین متحرک reward در validation

۳-۶-۳ معیار همگرایی

آموزش تا حداکثر ۱۰۰۰ اپیزود (≈ ۷۲۰,۰۰۰ گام) یا رسیدن به همگرایی پایدار ادامه می‌یابد. معیار همگرایی به‌صورت زیر تعریف می‌شود:

- هر ۱۰ اپیزود، یک ارزیابی روی validation set انجام می‌شود (میانگین reward در ۵ اپیزود تست با $\epsilon=0$).
- اگر میانگین reward در validation برای ۵۰ اپیزود متوالی هیچ بهبودی نداشته باشد ($\text{patience}=50$)، آموزش متوقف می‌شود.
- بهترین مدل (با بالاترین validation reward) ذخیره و در ارزیابی نهایی استفاده می‌شود.

این معیار، نسبت به نسخه قبلی («تغییر کمتر از ۱٪ در میانگین متحرک ۲۰ اپیزود») قوی‌تر است زیرا (الف) از معیار جداگانه validation استفاده می‌کند که جلوی Overfitting را می‌گیرد، (ب) با patience بزرگتر در برابر نوسانات تصادفی ABM مقاوم‌تر است.

۴-۶-۳ استفاده از Double DQN

در ارزیابی نهایی، Double DQN (van Hasselt et al., 2016) نیز پیاده‌سازی می‌شود تا مشکل بیش‌تخمینی (Overestimation Bias) مقادیر Q در DQN استاندارد کاهش یابد. این نسخه از همان معماری شبکه استفاده می‌کند اما در محاسبه target از انتخاب اقدام و ارزیابی آن استفاده می‌کند:

$$y_t^{DDQN} = r_t + \gamma \cdot Q(s_{t+1}, \arg\max_{a'} Q(s_{t+1}, a'; \theta); \theta^-) \quad (36-)$$

نتایج Double DQN در فصل چهارم به‌عنوان یک نسخه بهبودیافته از DQN استاندارد گزارش خواهد شد.

۷-۳ یکپارچه‌سازی ABM و DQN

۱-۷-۳ رابط حالت (State Interface)

رابط حالت، وضعیت ABM را به بردار حالت سراسری $s_t \in \mathbb{R}^{32}$ تبدیل می‌کند. نکته مهم: state در سطح ناحیه فعال (Active Zone) محاسبه می‌شود، نه کل شهر. تعریف ناحیه فعال:

- در هر گام ۲ دقیقه‌ای، نواحی به ترتیب پردازش می‌شوند (دور-رابین تصادفی).
 - برای هر ناحیه فعال z ، یک بردار حالت $s_t(z)$ ساخته می‌شود که در آن مؤلفه $zone_id$ متناظر با $z=1$ و بقیه
 - هستند، و مؤلفه‌های ناحیه‌ای ($mean_WT_zone$ ، $n_available_drivers$ ، DU_zone و غیره) به مقادیر آن ناحیه اشاره می‌کنند.
 - کاندیدها فقط شامل رانندگان آن ناحیه (با شعاع ۵ کیلومتر) هستند.
- این طراحی، dispatcher را به‌صورت یک عامل ناحیه‌محور تبدیل می‌کند که در هر گام ۱۴ بار اجرا می‌شود — یکبار برای هر ناحیه. تمامی مقادیر پیوسته پیش از بازگشت با پارامترهای Min-Max محاسبه‌شده از داده‌های آموزش نرمال‌سازی می‌شوند.

۲-۷-۳ رابط اقدام و پروتکل ساخت گذار

این بخش یکی از کلیدی‌ترین تفاوت‌های نسخه نهایی با نسخه‌های اولیه است. در نسخه اولیه، نحوه تبدیل تخصیص‌های دسته‌ای به گذارهای آموزشی DQN مبهم بود. در نسخه نهایی، پروتکل صریح زیر تعریف می‌شود:

تعریف یک گذار (Transition)

هر اجرای رابط اقدام (یعنی هر بار که dispatcher یک جفت کاندید انتخاب می‌کند) یک گذار مستقل تولید می‌کند:

$$transition = (s_t, a_features_chosen, r_step, s_{t+1}, done) \quad (37-)$$

که در آن:

- s_t : بردار حالت در لحظه قبل از انتخاب کاندید
- $a_features_chosen$: بردار ۸ ویژگی جفت انتخاب‌شده
- r_step : پاداش جزئی (Partial Reward) که فقط مربوط به این تخصیص است:

$$r_{\text{step}} = -\alpha \cdot (\text{pickup_eta} / \text{WT_baseline}) + \beta \cdot (1 / N_{\text{drivers_zone}}) - \lambda \cdot \mathbb{1}[\text{reject}]$$

(۳۸)

• s_{t+1} : بردار حالت پس از این تخصیص (بهروزرسانی state پس از انتخاب)

done: True فقط در گام پایانی روز ($T=720$)

توجیه پاداش جزئی: جمله اول تخمین مستقیم سهم این تخصیص در WT است (زمان رسیدن راننده). جمله دوم سهم در DU است که با معکوس تعداد رانندگان ناحیه نرمال شده. جمله سوم جریمه رد. این پاداش جزئی، مزیت کلیدی نسبت به پاداش سراسری گام دارد: عامل DQN می‌تواند مستقیماً تأثیر هر تخصیص را یاد بگیرد بدنبال نسبت دادن (Credit Assignment) به یک پاداش تجمعی.

این طراحی به‌طور خاص مسئله credit assignment را که در نسخه قبلی منبع ابهام بود برطرف می‌کند. هر گام ۲ دقیقه‌ای می‌تواند چندین گذار تولید کند (به تعداد جفت‌های انتخاب‌شده در آن گام)، و هر گذار یک نمونه آموزشی مستقل به بافر تجربه اضافه می‌کند.

۳-۷-۳ رابط پاداش (Reward Interface)

رابط پاداش دو نوع پاداش محاسبه می‌کند: (الف) پاداش جزئی برای هر گذار آموزشی (رابطه ۸-۳) که به DQN داده می‌شود؛ (ب) پاداش سراسری گام (رابطه ۴-۳) که برای logging و معیار همگرایی استفاده می‌شود. این تفکیک، صراحت طراحی را افزایش می‌دهد.

۴-۷-۳ حلقه آموزش و توصیف معماری یکپارچه

معماری یکپارچه‌سازی از نوع «ABM به عنوان محیط» (ABM-as-Environment) است که در بخش ۲-۵-۲ فصل دوم به عنوان معماری منتخب این پژوهش معرفی شد. در این معماری، مدل ABM نقش محیط استاندارد MDP را ایفا می‌کند و عامل DQN از طریق تعامل مکرر با آن، سیاست بهینه را می‌آموزد. سرت و همکاران (Sert et al., 2020) یکی از نخستین پیاده‌سازی‌های مستند این نوع معماری را در حوزه سیستم‌های اجتماعی ارائه کردند. پژوهش حاضر، این معماری را در حوزه تخصیص تاکسی آنلاین با داده‌های واقعی پیاده‌سازی و اعتبارسنجی می‌کند.

الگوریتم ۲. حلقه کلی آموزش DQN+ABM

Algorithm 2: DQN+ABM Closed-Loop Training

Input: ABM environment, replay buffer B (size 100k), DQN networks Q_{θ} , $Q_{\theta_{\text{minus}}}$

Hyperparameters: $\text{lr}=5\text{e-}4$, $\text{batch}=64$, $\text{gamma}=0.95$, epsilon schedule, $T_{\text{total}}=720$

Initialize: Q_{θ} with random weights, $Q_{\theta_{\text{minus}}} = Q_{\theta}$, $B = \text{empty}$

for episode = 1, 2, ..., 1000:

$s_0 \leftarrow \text{ABM.reset}(\text{seed} = \text{episode})$

$\text{episode_reward} \leftarrow 0$

for $t = 0, 1, \dots, 719$:

For each active zone (round-robin)

for zone in shuffled(zones):

$s_t \leftarrow \text{get_state}(\text{zone})$

```

candidates <- build_candidates(zone)
# Sequential assignment within zone
while candidates not empty:
    if random() < epsilon: a <- random(candidates)
    else: a <- argmax_c Q_theta(s_t, action_features(c))
    (driver, passenger) <- a
    accepted <- driver.decide_accept(passenger) // Eq. 3-5
    execute_assignment(driver, passenger, accepted)
    r_step <- compute_partial_reward(driver, passenger, accepted) // Eq.
3-8

s_t_plus <- get_state(zone) // updated state
B.store((s_t, action_features(a), r_step, s_t_plus, done))
candidates <- filter_out(a)
s_t <- s_t_plus
# Train step every K transitions
if len(B) > warmup_steps and t % train_freq == 0:
    batch <- B.sample(64)
    y <- r + gamma * max_a' Q_theta_minus(s', a') # or DDQN target
    loss <- Huber(Q_theta(s, a), y)
    optimizer.step(loss)
if t % target_update_freq == 0:
    Q_theta_minus <- Q_theta
ABM.advance_step()
decay_epsilon()
# Validation every 10 episodes
if episode % 10 == 0:
    val_reward <- evaluate(Q_theta, validation_env)
    if val_reward > best_val_reward:
        best_val_reward <- val_reward; patience_counter <- 0
        save_best_model(Q_theta)
    else: patience_counter += 1
    if patience_counter >= 50: break // Early stopping

```

۸-۳ الگوریتم‌های خطمبنا و آزمایش‌های Ablation

۱-۸-۳ خطمبنای تصادفی (Random Baseline)

در هر گام تصمیم، یکی از جفت‌های کاندید به‌صورت تصادفی یکنواخت انتخاب می‌شود. این خطمبنا حد پایین عملکرد را تعریف می‌کند. پیچیدگی محاسباتی: $O(1)$.

۲-۸-۳ خطمبنای حریصانه (Greedy Nearest-Driver)

نزدیک‌ترین راننده به مسافر انتخاب می‌شود. این خطمبنا، رویکرد متعارف صنعت ride-hailing را نمایندگی می‌کند و معیار «بهبود بر صنعت» را فراهم می‌سازد. پیچیدگی محاسباتی: $O(n \log n)$.

۳-۸-۳ خطمبنای مجارستانی (Hungarian Algorithm)

ماتریس هزینه $C \in \mathbb{R}^{n \times m}$ با $\text{cost} = \text{pickup_distance}$ ساخته می‌شود و الگوریتم کوهن-مونکرز (Kuhn, 1955; Munkres, 1957) تخصیص بهینه دوبرخی را محاسبه می‌کند. این خط‌مبنا حد بالای عملکرد ایستا را تعریف می‌کند. پیچیدگی محاسباتی: $O(n^3)$.

۴-۸-۳ آزمایش‌های Ablation: ساختار و توجیه

برای پاسخ به سؤال اصلی ۲ پژوهش (تأثیر معماری ترکیبی بر شاخص‌ها)، دو شرط Ablation به‌صراحت طراحی شده‌اند. این بخش، در پاسخ به ابهام نسخه‌های قبلی درباره معنی «DQN-only» و «ABM-only»، تعریف عملیاتی هر کدام را ارائه می‌دهد:

الف) DQN-only: یادگیری در محیط ABM ساده‌شده

در این شرط، عامل DQN روی یک محیط ABM ساده‌شده آموزش داده می‌شود که در آن مؤلفه‌های کلیدی ABM حذف یا ساده شده‌اند:

- ناهمگنی راننده حذف می‌شود: همه رانندگان $\text{acceptance_rate} = 0.8$ ثابت دارند.
- اثرات کیفیت مقصد و طول سفر در تابع پذیرش حذف می‌شوند: $f_length = 1$ ، $f_dest = 1$.
- شرایط آبرو‌هویی به clear ثابت می‌شوند.
- ترجیحات ناحیه‌ای راننده حذف می‌شوند.

این شرط، فرضیه «ABM کامل برای آموزش DQN ضروری است» را آزمایش می‌کند. اگر DQN-only به عملکرد مشابه DQN+ABM دست یابد، ادعای ارزش‌افزوده ABM ضعیف می‌شود.

ب) ABM-only: شبیه‌سازی کامل با dispatcher غیر-RL

در این شرط، ABM کامل (با همه عوامل ناهمگن، آبرو‌ها، ترافیک و غیره) اجرا می‌شود، اما dispatcher از قاعده Greedy داخلی استفاده می‌کند به‌جای DQN. این شرط، فرضیه «DQN برای بهره‌برداری از غنای ABM ضروری است» را آزمایش می‌کند. اگر ABM-only به عملکرد مشابه DQN+ABM دست یابد، ادعای ارزش‌افزوده DQN ضعیف می‌شود.

ج) ماتریس کامل آزمایش‌ها

جدول ۸-۳. ماتریس آزمایش‌های Ablation و Baseline

نام	محیط شبیه‌سازی	سیاست تخصیص	هدف
Random	ABM کامل	انتخاب تصادفی	کران پایین
Greedy	ABM کامل	نزدیکترین راننده	خط‌مبنای صنعتی
Hungarian	ABM کامل	حل بهینه ایستا	حد بالای ایستا
ABM-only	ABM کامل	Greedy داخلی	Ablation: ارزش DQN
DQN-only	ABM ساده‌شده	DQN آموخته	Ablation: ارزش ABM
DQN+ABM	ABM کامل	DQN آموخته	مدل پیشنهادی

۹-۳ طرح ارزیابی و آزمون‌های آماری

۱-۹-۳ طرح آزمایش فاکتوریل

طرح آزمایش از نوع فاکتوریل کامل (Full Factorial) با سه عامل است: عامل اول ۶ سطح الگوریتم (شامل ۳ خط‌مبنا، ۱۲ Ablation مدل پیشنهادی)؛ عامل دوم ۳ سطح سناریو (نرمال، اوج، بارانی)؛ عامل سوم ۳۰ سطح بذر تصادفی. مجموع آزمایش‌ها: $6 \times 3 \times 30 = 540$ اجرا. هر اجرا شامل ۷۲۰ گام (یک روز کامل) است و شاخص‌های WT، DU و CR ثبت می‌شوند.

۲-۹-۳ محاسبه قدرت آماری و توجیه تعداد تکرارها

نسبت به نسخه قبلی که ۳۰ تکرار را بدون محاسبه قدرت آماری توجیه می‌کرد، نسخه نهایی شامل محاسبه صریح Power Analysis است.

برای آزمون Wilcoxon Signed-Rank، توان آماری حدود ۹۵٪ کارایی نسبت به t-test جفتی دارد (Lehmann, 1975). برای شناسایی اثر متوسط ($d = 0.5$) با $n = 30$ در $\alpha = 0.05$ ، توان آماری $t\text{-test} \approx 0.75$ و $Wilcoxon \approx 0.71$ است. این مقدار از حد توصیه‌شده ۰.۸ کمتر است.

بنابراین در نسخه نهایی، $n = 40$ تکرار انتخاب شده است که توان Wilcoxon را به ≈ 0.85 افزایش می‌دهد — کافی برای دفاع از مرز آماری استاندارد. این محاسبه با کتابخانه statsmodels.stats.power انجام و در پیاده‌سازی فصل ۴ مستند می‌شود. مجموع آزمایش‌ها به $6 \times 3 \times 40 = 720$ اجرا افزایش می‌یابد.

نکته: اگر تخمین اولیه نشان دهد $d > 0.8$ است (اثر بزرگ)، $n = 30$ کافی خواهد بود و گزارش پایانی این موضوع را به‌صراحت مطرح خواهد کرد.

۳-۹-۳ آزمون‌های آماری

جدول ۹-۳. طرح آزمون‌های آماری متناظر با سؤالات پژوهشی

سؤال	موضوع	آزمون اصلی	آزمون پسین / اندازه اثر
۱	بهبود CR نسبت به خط‌مبنا	Wilcoxon Signed-Rank	تصحیح Bonferroni؛ Cohen's d
۲	تأثیر بر WT و DU	ANOVA یک‌طرفه (۶ گروه)	η^2 ؛ Tukey HSD
۲-ablation	ارزش‌افزوده DQN و ABM	Wilcoxon (جفتی)	Cohen's d؛ Bonferroni
۳	تطبیق‌پذیری در سناریوها	Kruskal-Wallis	آزمون دان با Bonferroni؛ ϵ^2

توضیحات تکمیلی:

• سؤال ۱ (Wilcoxon Signed-Rank): مقایسه جفتی DQN+ABM با هر کدام از خط‌مبناهای ۳ مقایسه و تصحیح (Bonferroni) ($\alpha_{\text{adjusted}} = 0.05/3 \approx 0.017$).

• سؤال ۲ (ANOVA): مقایسه ۶ گروه (شامل Ablation). پیش‌فرض‌ها با Shapiro-Wilk (نرمالی) و Levene (همگنی واریانس) بررسی می‌شوند. اگر رد شدند، Kruskal-Wallis جایگزین می‌شود.

- سؤال ۲-ablation: مقایسه‌های جفتی صریح DQN+ABM با DQN-only و DQN+ABM با ABM-only برای جداسازی ارزش‌افزوده هر مؤلفه.
- سؤال ۳ (Kruskal-Wallis): مقایسه عملکرد DQN+ABM در ۳ سناریو. اگر معنادار شد، Dunn's post-hoc با Bonferroni اجرا می‌شود.

۴-۹-۳ روایی و پایایی

روایی درونی (Internal Validity): کنترل متغیرهای مزاحم از طریق استفاده از بذره‌های تصادفی یکسان برای هر جفت مقایسه‌ای، محیط شبیه‌سازی یکسان برای همه الگوریتم‌ها (به‌جز Ablation که محیط‌اش متفاوت است و این تفاوت موضوع آزمایش است)، و داده‌های ورودی یکسان.

روایی بیرونی (External Validity): استفاده از داده‌های واقعی ۱۰۴,۷۷۰ درخواست از بازار تهران و کالیراسیون ABM با ۶ معیار POM، تعمیم‌پذیری به شرایط واقعی را تقویت می‌کند. با این حال، تعمیم به شهرهای دیگر نیاز به کالیراسیون مجدد دارد.

پایایی ۴۰ (Reliability): بار تکرار با بذره‌های متفاوت، گزارش فاصله اطمینان ۹۵٪، ثبت کامل بذره‌های تصادفی، ذخیره مدل‌های نهایی، و افشای کد در یک مخزن عمومی (پس از دفاع) برای بازتولیدپذیری کامل.

۵-۹-۳ طراحی تحلیل حساسیت

نکته روش‌شناختی: تحلیل حساسیت در نسخه نهایی به‌صراحت طراحی شده تا پاسخ به هدف اختصاصی ۵ پژوهش را فراهم کند. سه نوع تحلیل حساسیت انجام می‌شود:

الف) حساسیت ضرایب تابع پاداش

شش ترکیب (α, β, λ) آزمایش می‌شود تا اثر وزن‌دهی بر عملکرد بررسی شود:

ترکیب	α	β	λ	توجیه
پایه	۰.۶	۰.۴	۰.۲	انتخاب نهایی
متعادل	۰.۵	۰.۵	۰.۲	وزن یکسان WT و DU
WT-محور	۰.۸	۰.۲	۰.۲	تأکید قوی بر مسافر
DU-محور	۰.۳	۰.۷	۰.۲	تأکید قوی بر راننده
بدون جریمه	۰.۶	۰.۴	۰	حذف اثر جریمه رد
جریمه شدید	۰.۶	۰.۴	۰.۵	تأکید قوی بر کاهش رد

ب) حساسیت فرارامترهای DQN

سه فرارامتر کلیدی با Grid Search روی validation set آزمایش می‌شوند:

• نرخ یادگیری: $\{1e-4, 5e-4, 1e-3\}$

• ضریب تنزیل γ : $\{0.90, 0.95, 0.99\}$

• اندازه بافر تجربه: $\{50k, 100k, 200k\}$

ج) حساسیت سناریویی

عملکرد DQN+ABM در ۹ سناریوی ترکیبی (۳ سطح تقاضا $\times$ ۳ شرط آبوهوایی) مقایسه می‌شود تا پایداری سیاست در شرایط مختلف ارزیابی شود.

۱۰-۳ ابزارها و محیط محاسباتی

پشته فناوری انتخاب‌شده کاملاً Python-native است که قابلیت بازتولید و دسترسی پژوهشگران ایرانی را افزایش می‌دهد:

جدول ۱۰-۳. پشته فناوری پژوهش

نقش	نسخه	ابزار	مؤلفه
پلتفرم ABM	≤ 2.1	Mesa	مدلسازی عامل‌بنیان
پیداده‌سازی DQN	≤ 2.0	PyTorch	شبکه عصبی
Wrapper آموزش	≤ 2.0	Stable-Baselines3	یادگیری تقویتی
رابط استاندارد	≤ 0.29	Gymnasium	محیط RL
پیش‌پردازش و تحلیل	—	pandas, NumPy	پردازش داده
آزمون‌های آماری	—	scipy, statsmodels	تحلیل آماری
نمودارها	—	matplotlib, seaborn	تجسم
ثبت اجراها و فرایارامترها	—	MLflow	مدیریت آزمایش

محیط محاسباتی: سرور با CPU چند هسته‌ای (≤ 8 هسته)، GPU NVIDIA، RAM ۳۲ GB با حداقل ۸ GB VRAM (برای تسریع آموزش DQN). تخمین زمان اجرا: کالیبراسیون ≈ 20 ساعت، آموزش ≈ 48 ساعت، اجرای ۷۲۰ آزمایش ارزیابی ≈ 72 ساعت.

بازتولیدپذیری: شماره بذر هر اجرا ثبت و در فایل نتایج ذخیره می‌شود. از بذره‌های ۱ تا ۴۰ برای ۴۰ تکرار آزمایش استفاده می‌شود. تمام فرایارامترها، نسخه کتابخانه‌ها، و کد در فایل requirements.txt و یک نمونه YAML پیکربندی ذخیره می‌شوند.

۱۱-۳ جمع‌بندی فصل

در این فصل، تمامی تصمیمات طراحی و جزئیات اجرایی لازم برای بازتولید سیستم پیشنهادی به‌صورت جامع ارائه شد. مجموعه داده ۱۰۴,۷۷۰ رکوردی با ۳۶ ستون به‌تفصیل توصیف شد و تعریف عملیاتی وضعیت‌های ترکیبی $(acceptance_status \times trip_status)$ برای رفع ابهام مدلسازی ارائه گردید.

فرمول‌بندی ریاضی مسئله در قالب MDP با چهار ویژگی اصلی تعریف شد: (۱) بردار حالت ۳۲ بُعدی (جدول ۳-۳)؛ (۲) معماری $Q(s, a_features)$ برای فضای اقدام (که مسئله permutation-dependence نسخه‌های

اولیه را برطرف می‌کند؛ (۳) تابع پاداش ترکیبی با جریمه رد (رابطه ۴-۳) و تابع پاداش جزئی برای ساخت گذار (رابطه ۸-۳)؛ (۴) پروتکل صریح ساخت گذار در تخصیص دسته‌ای.

معماری مدل عامل‌بنیان با سه نوع عامل و مدل پذیرش راننده گسترش‌یافته (شامل اثرات کیفیت مقصد و طول سفر) طراحی و با شش معیار POM (جدول ۸-۳) از داده‌های واقعی کالیبره شد. معماری DQN با شبکه چهار لایه (۴۰ $\rightarrow$ ۲۵۶ $\rightarrow$ ۲۵۶ $\rightarrow$ ۱۲۸ $\rightarrow$ ۱) و جدول کامل فرایارامترها (جدول ۷-۳) با توجه مستند تعیین گردید. آموزش به ۱۰۰۰ اپیزود با (early stopping (patience=۵۰) گسترش یافت.

یکپارچه‌سازی DQN و ABM با سه رابط (حالت، اقدام، پاداش) و شبه‌کد کامل (الگوریتم‌های ۱ و ۲) تشریح شد. سه الگوریتم خط‌منا (Random، Greedy، Hungarian) و دو آزمایش ABM-، Ablation (DQN-only، only) به‌صراحت تعریف شدند تا ارزش‌افزوده هر مؤلفه قابل اندازه‌گیری باشد (جدول ۸-۳).

طرح آزمایش فاکتوریل کامل (۶ $\times$ ۳ $\times$ ۴۰ = ۷۲۰ اجرا) با محاسبه قدرت آماری صریح و آزمون‌های آماری متناسب با هر سؤال پژوهشی (جدول ۹-۳) تعیین شدند. تحلیل حساسیت سه‌بعدی (ضرایب پاداش، فرایارامترها، سناریوها) برای ارزیابی پایداری سیاست طراحی شد.

جدول ۱۱-۳. نگاشت نهایی سؤالات پژوهشی به مؤلفه‌های روش‌شناسی

خروجی	آزمون	مؤلفه روش‌شناسی	موضوع	سؤال
بهبود معنادار CR با $d \geq 0.5$	Wilcoxon	DQN+ABM در برابر ۳ خط‌منا	بهبود CR	۱
بهبود معنادار DU و WT	ANOVA + Tukey	مقایسه ۶ الگوریتم	تأثیر بر WT و DU	۲
تفکیک ارزش هر مؤلفه	Wilcoxon جفتی	DQN-only و ABM-only	ارزش‌افزوده DQN/ABM	۲-abl
عملکرد پایدار	Kruskal-Wallis	DQN در ۳ سناریو	تطبیق‌پذیری	۳

در فصل چهارم، نتایج اجرای این طرح آزمایشی ارائه، تحلیل و تفسیر خواهند شد.

منابع فصل سوم

- Arlot, S., & Celisse, A. (2010). A survey of cross-validation procedures for model selection. *Statistics Surveys*, 4, 40–79.
- Fu, M. C. (Ed.). (2015). *Handbook of simulation optimization*. Springer.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.
- Grimm, V., Revilla, E., Berger, U., Jeltsch, F., Mooij, W. M., Railsback, S. F., ... DeAngelis, D. L. (2005). Pattern-oriented modeling of agent-based complex systems: Lessons from ecology. *Science*, 310(5750), 987–991.
- Kazil, J., Masad, D., & Crooks, A. (2020). Utilizing Python for agent-based modeling: The Mesa framework. In *Social, Cultural, and Behavioral Modeling* (pp. 308–317). Springer.
- Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. *ICLR 2015*.
- Kuhn, H. W. (1955). The Hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 2(1-2), 83–97.

- Lehmann, E. L. (1975). *Nonparametrics: Statistical methods based on ranks*. Holden-Day.
- Lin, L.-J. (1992). Self-improving reactive agents based on reinforcement learning, planning and teaching. *Machine Learning*, 8(3-4), 293–321.
- Masad, D., & Kazil, J. (2015). Mesa: An agent-based modeling framework. In *Proceedings of the 14th Python in Science Conference* (Vol. 2015, pp. 53–60).
- Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., ... Hassabis, D. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529–533.
- Munkres, J. (1957). Algorithms for the assignment and transportation problems. *Journal of the Society for Industrial and Applied Mathematics*, 5(1), 32–38.
- Saunders, M., Lewis, P., & Thornhill, A. (2019). *Research methods for business students* (8th ed.). Pearson.
- Sert, E., Bar-Yam, Y., & Morales, A. J. (2020). Segregation dynamics with reinforcement learning and agent based modeling. *Scientific Reports*, 10(1), 11771.
- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement learning: An introduction* (2nd ed.). MIT Press.
- Tang, X., Qin, Z., Zhang, F., Wang, Z., Xu, Z., Ma, Y., ... Ye, J. (2019). A deep value-network based approach for multi-driver order dispatching. In *KDD 2019*.
- van Hasselt, H., Guez, A., & Silver, D. (2016). Deep reinforcement learning with double Q-learning. In *AAAI 2016* (Vol. 30, No. 1).
- Vinyals, O., Fortunato, M., & Jaitly, N. (2015). Pointer networks. *NeurIPS 2015*.
- Walker, W. E. (1998). Policy analysis: A systematic approach to supporting policymaking in the public sector. *Journal of Multi-Criteria Decision Analysis*, 9(1-3), 11–27.
- Windrum, P., Fagiolo, G., & Moneta, A. (2007). Empirical validation of agent-based models: Alternatives and prospects. *Journal of Artificial Societies and Social Simulation*, 10(2), 8.